```
SELECT respuesta FROM pregunta_en_español;
```

Text-to-SQL con LoRA

Qwen2.5-Coder-1.5B-Instruct ajustado para generar consultas MySQL desde preguntas en español

Anggie Quezada · **Iris Ayala**

Deep Learning 2026 · Universidad del Valle de Guatemala
Proyecto 3 · 25 de octubre de 2026

ENFOQUE

Un modelo pequeño, adaptado y con red de seguridad

Entrada

El esquema con SHOW CREATE TABLE (PK, FK y COMMENT) y la pregunta en español.

El esquema se compacta (sin ENGINE, COLLATE ni índices): **~37 % menos tokens**.

Modelo

Qwen2.5-Coder-1.5B-Instruct con un adapter LoRA (r=16, alpha=32).

Generación greedy y semilla fija 2026: la misma pregunta da la misma consulta.

Salida segura

Solo sale un **SELECT** o **WITH**; si no, se devuelve SELECT 1.

Autocorrección con ejecutar: máx. 3 llamadas, dentro de los 30 s.

solucion.py · config.json (usar_adapter true / false)

DATOS · SPIDER

De Spider en SQLite a MySQL 8.4.10 en español

Pares originales (166 bases)	**9,693**
Se ejecutan en MySQL (sqlglot)	**9,516 −177**
Traducidos con valores intactos	**8,261 −1,255**
Muestra para entrenamiento	**6,000**

Por qué se descartaron 177 en MySQL

Motivo	Pares
ONLY_FULL_GROUP_BY	91
Duplicados	25
ORDER BY fuera de DISTINCT	24
Derivada sin alias	11
Agregado sin GROUP BY	10
Otros (sintaxis, columnas)	16

Traducción con MarianMT (opus-mt-en-es). Si un valor literal cambia (“English” → “Inglés”), se reintenta entre comillas; si se pierde, el par se descarta.

datos/descartes/spider_resumen.json · traduccion_descartes.csv

DATOS · ESQUEMAS PROPIOS Y DATASET FINAL

12 esquemas propios para parecerse a la evaluación

960
pares propios: 80 por esquema (25 fáciles, 30 medios, 25 difíciles)

7,920
ejemplos: 6,000 de Spider + 960 propios ×2

169
esquemas distintos en entrenamiento

302
pares de dev interno, de 8 bases apartadas por esquema

Esquemas generados con un LLM

8–9 tablas, nombres en español, inglés y abreviados, con COMMENT, fechas, CTE y funciones de ventana. Los 960 pares corren en MySQL y ninguno devuelve 0 filas.

Largo de contexto: 3,072 tokens

Con COMMENT un esquema mide 1,500–2,500 tokens; con 2,048 se perdían 553 pares propios. Mediana 704 tokens, p95 2,290; 63 descartados por largo.

datos/esquemas_propios/ · datos/entrenamiento/resumen.json

ENTRENAMIENTO · CONFIGURACIONES

Dos configuraciones, un solo factor: dónde va LoRA

	A · solo atención	B · atención + MLP
Módulos	q, k, v, o	q, k, v, o, gate, up, down
Parámetros entrenables	4,358,144 (0.282 %)	18,464,768 (1.182 %)
Tiempo por paso (T4)	~23 s (~3 h, en 3 sesiones)	~23 s (189 min en total)
Loss en dev interno	0.1174 (perplejidad 1.125)	0.0997 (perplejidad 1.105)

HIPÓTESIS, ESCRITA ANTES DE ENTRENAR

B logrará menor loss en dev y mayor EX que A: las capas MLP guardan los patrones (sintaxis MySQL, fechas, ventanas). A cambio, B tendrá ~2.5× más parámetros y será más lento por paso.

Resultado: B tiene 4.2× más parámetros, no 2.5×.

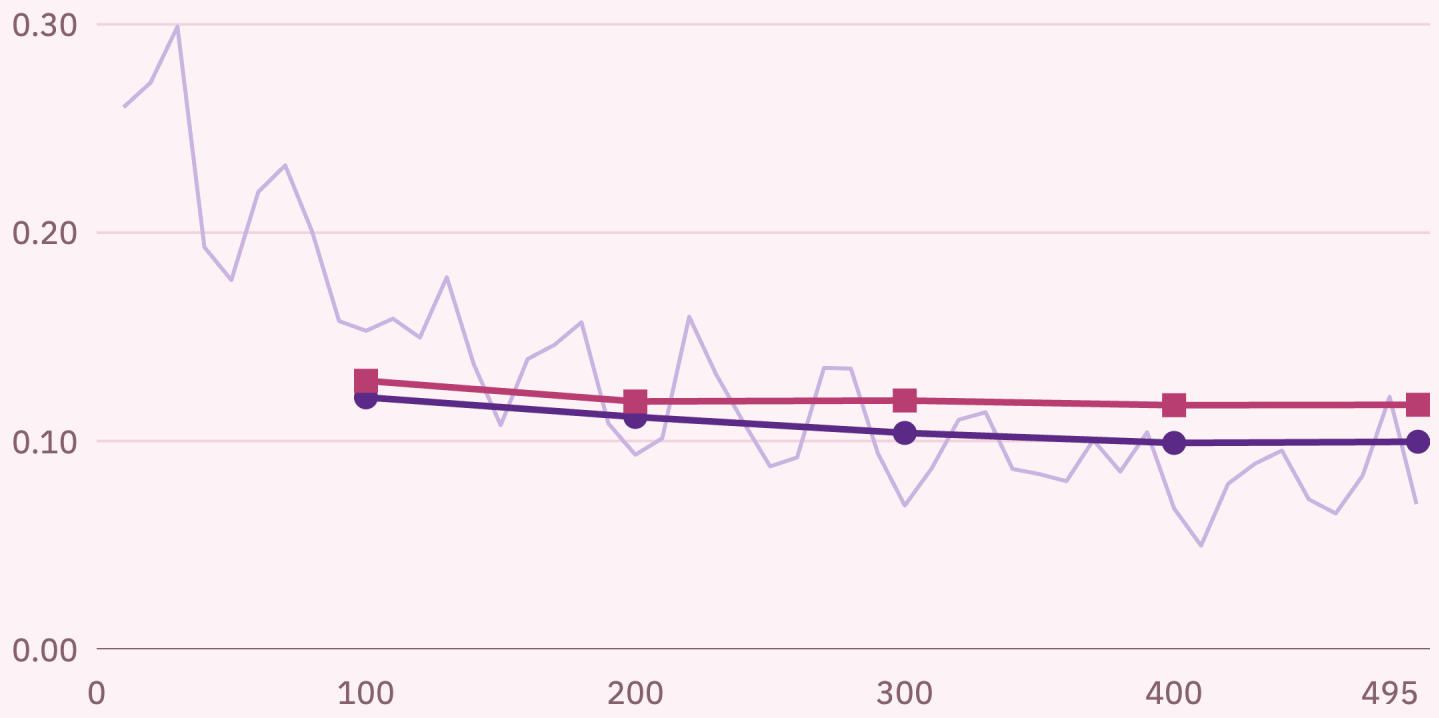
IGUAL EN AMBAS

r=16, alpha=32, dropout 0.05, lr 2e-4 coseno, 1 época (495 pasos), batch efectivo 16, fp16, loss solo sobre el SQL.

resultados/entrenamiento/A y B · resumen.json · Colab T4, checkpoints cada 50 pasos en Drive

ENTRENAMIENTO · CURVAS DE LOSS

B queda por debajo de A en cada evaluación



● B · dev interno
0.121 → 0.0997 (paso 495)

— B · train
0.26 → ~0.06

■ A · dev interno
0.129 → 0.1174 (paso 495)

A se aplana desde el paso 200; B sigue bajando hasta el 400.

Eje x: paso de entrenamiento · eje y: loss (entropía cruzada sobre el SQL) · resultados/entrenamiento/*/historial.json

VALIDACIÓN PROPIA

Dos esquemas no vistos y 40 preguntas propias

	Gimnasio	Café
Tablas	9	9
Nombres	En español (socios, pagos)	Abreviados (prod, fca, lot)
Datos	2022–2025	2022–2025

Nivel	Peso	Gim.	Café
Fácil (una tabla)	1	7	7
Media (JOIN, GROUP BY)	2	7	7
Difícil (WITH, ventana)	3	6	6

evaluar.py imita al del docente

- Compara por ejecución, no por texto.
- Redondea a 2 decimales; el orden cuenta solo si se pide; una columna extra no penaliza.
- ejecutar(sql) de solo lectura, máximo 3 llamadas.
- Más de 30 s o algo que no sea SELECT/WITH es error.
- Con las consultas de referencia: EX = 1.000.
- COMMENT en todo y partición por esquema: verificar_fuga.py, sin fuga.

datos/validacion/ · scripts/evaluacion/evaluar.py · EX ponderada = pesos acertados / pesos totales

RESULTADOS · EX PONDERADA

B es el adapter de la entrega: 0.590 de EX

Configuración	EX	Fáciles	Medias	Difíciles	Gimnasio	Café
Baseline (sin adapter)	0.474	14/14	7/14	3/12	0.487	0.462
LoRA A (atención)	0.577	14/14	8/14	5/12	0.692	0.462
LoRA B (atención + MLP)	0.590	14/14	10/14	4/12	0.641	0.538

+0.116

de EX sobre el baseline con B

Hipótesis ✓

B: menor loss (0.0997 vs 0.1174) y mayor EX que A

10/14

medias con B, contra 8/14 con A: ahí está su ventaja

resultados/validacion_propia.csv · resultados/ex_por_config.png

EXPERIMENTO DE INFERENCIA

Autocorrección con ejecutar: ganancia neta cero

LoRA B	EX	Error de columna	Resultado distinto	Tiempo máx.
Con ejecutar (corrige con el error de MySQL)	0.590	3	8	10.5 s
Sin ejecutar (una sola respuesta)	0.590	4	7	3.3 s

Qué pasó

Corrigió un error de columna, pero la consulta nueva devolvió un resultado distinto.

Por qué no ayuda más

Los errores que quedan son lógicos: MySQL no marca error, así que no hay nada que corregir.

Decisión

Se mantiene: no empeora y el tiempo queda lejos del límite de 30 s.

resultados/validacion_propia.csv · configuraciones con y sin ejecutar

ANÁLISIS DE ERRORES · LORA B, 12 DE 40

Cero errores de sintaxis: lo que falla es la lógica

Categoría	Errores	Ejemplo
Agregación	5	Salario más alto de toda la cadena en vez de por sede
Columna inexistente	3	Inventa fca.lot_id y se salta la tabla lot
Filtro	2	Falta estado = 'pagada'
JOIN	1	Une productores y catación por nombre del catador
Resultado distinto	1	DATEDIFF (días) cuando se piden minutos
Sintaxis	0	—

9 de 12

errores son preguntas difíciles

3 de 3

errores de columna en el esquema abreviado: le cuesta seguir caminos de 3 tablas

resultados/errores_lora_B.csv · resultados/errores_lora_B.png

PREDICCIÓN DE LA EVALUACIÓN OCULTA

Esperamos EX ≈ 0.55 con el adapter B

0.55

rango 0.48–0.62

mejora esperada sobre el modelo sin adapter: +0.10 a +0.12

Evidencia	Valor
EX de B en la validación	0.590
EX de B, esquema abreviado	0.538
Fáciles / medias / difíciles	100 / 71 / 33 %
Mejora sobre el baseline	+0.116
Tiempo máximo por pregunta	10.5 s

La prueba puede traer nombres abreviados o en inglés, donde B rinde menos; la variación viene de las difíciles (peso 3).

Predicción basada en la validación propia con LoRA B y autocorrección

CONCLUSIONES

Lo que aprendimos

El fine-tuning aporta

Con LoRA B la EX sube de 0.474 a 0.590 (+0.116) entrenando solo el 1.18 % de los parámetros.

Las capas MLP importan

Adaptar también el MLP dio menor loss y mayor EX que adaptar solo la atención, como planteaba la hipótesis.

Los errores son de lógica

Cero errores de sintaxis; fallan la agregación, los filtros y los caminos de JOIN en esquemas abreviados.

Siguiente paso

Más ejemplos difíciles y con nombres abreviados en el entrenamiento, donde el modelo todavía falla.

Gracias

Anggie Quezada · Iris Ayala

¿Preguntas?